KGI【專家會議】AI軟硬體產業專家

20261016

一、主講內容

1. Google 大模型研發情況

- **Agentic 能力與 Harness 設計**：當前系統 Harness 越做越薄，核心能力移轉至模型本身。若要具備優秀的 Agentic 能力，必須收集大量用戶交互軌跡數據（包含正確與錯誤的工具選擇與執行軌跡）。
- **數據合規與採購策略**：Codex 與 Claude Code 透過更新用戶條款，合規地使用脫敏 C 端用戶數據進行訓練且無 Retention 隱患。Google 則堅持不使用 C 端數據訓練的條款，為解決網路缺乏原生軌跡數據的瓶頸，Google 採用內部員工數據並結合 2–3 家高質量數據提供商，於今年下半年補齊數據劣勢。

2. Google TPU 出貨量、算力分配與吃緊現況

- **算力存量與配置**：Google 目前 **TPU 總存量約 700 多萬顆**（含 TPU v3/v4/v7 等各式世代），另有約 **100 萬顆 GPU** 及部分外租 GPU。
- **結構性算力擠壓**：
    - **傳統搜廣推業務**：YouTube、Search 及廣告等傳統業務佔用將近 200 萬顆中低端 TPU（如 TPU v4）。
    - **外部客戶**：佔用約 300 萬至 350 萬顆 TPU，其中 Anthropic (Claude Fable) 訓練與 Serving 消耗大量 TPU v7。
    - **C 端與新模型**：Gemini 免費端用戶算力遭大幅削減（限制使用 Flash，改推 Flash Lite），以節省算力支援新模型 Argon (Gemini 4 Argon) 上線。
    - **DeepMind 預訓練與外部客戶**：DeepMind 本身預訓練占用幾十萬張卡；外部客戶（如 Ilya's SSI）因排隊等不到 TPU 而轉向 NVIDIA GPU。
- **未來展望**：預計明年 TPU 規模維持在 600–700 萬顆左右，因資料中心建設與晶片延遲（如 TPU v8i Delay），遠期供需仍充滿不確定性。

3. 海外主流 LLM 發展水準與跨領域能力差異

- **Coding 領域**：第一梯隊（前 6 款模型）能力極度接近，評比關鍵在於**輸出速度**與**可讀性**，而非單純的幻覺率。第一梯隊與第二梯隊（如開源 OpenCode）在配備良好 Harness 時差距亦顯著收窄。
- **高價值領域（金融與法律）**：第一梯隊與第二梯隊存在約 **1 個代差**。金融（如 Finance Agent, Accounting, CFA 評測）與法律領域商業價值極高，頭部 Lab（如 OpenAI 專屬團隊、Gemini Enterprise 預置 Agent）皆進行大量專項優化。
- **前沿領域（3D 生成與 Science/Life Science）**：

    - **3D 生成**：第一梯隊領先 2–3 個代差。如 Opus 5.5 Max 可生成極複雜 3D 場景（例如 7-Eleven 超市整排貨架商品），供具身智能/機器人訓練；技術源自透過操作 **Blender** 進行驗證。
    - **Science / Life Science**：在 Physics、OmniScience 等榜單上第一梯隊具備壓倒性優勢，影響 Robotics、無人車、World Model 及 Gaming 領域。
- **產業架構同質化**：自 Claude 4.6 爆紅後，各家在模型架構、訓練方法（RL/Reasoning）上全面趨同，競爭轉向數據與執行力。

4. 中系模型研發追趕迅速之主因

- **架構無本質差別**：皆基於標準 Transformer（搭配 Sliding Window Attention，亦可透過 Agent 實現高效注意力）。
- **算力並非絕對劣勢**：雖然無法大規模採購頂級卡，但透過租賃可取得小幾十萬級（10萬–20萬張）GPU 進行訓練，仍能跟緊第二梯隊。
- **靈活運用蒸餾（Distillation）：**矽谷公司因法律合規顧慮不蒸餾其他模型；中系模型可透過蒸餾進行思維鏈（CoT）對齊、Action 對齊與結果對齊，大幅節省數據標註與採集成本。
- **數據規範與人才**：數據合規限制相對較低，可購買其他模型之用戶軌跡數據；且研發團隊許多畢業自同等名校，基礎人才儲備充沛。

5. LLM成為大眾商品的條件

- **大眾需求本質**：普通用戶主要需要個人助理與跑腿服務（搶票、盯價、撥打電話），對專業評測榜單並不敏感。
- **產品設計激進程度決定勝負：**
    - **Muse (Meta)**：產品設計極其激進，協助搶票盯價、自動幫用戶跳過人機驗證（CAPTCHA）、打電話給客服時以用戶身份對話而不聲明自己是 AI、主動要求支付方式，體驗流暢。
    - **ChatGPT/Claude/Gemini Spark**：設計保守，受限於合規規範，會主動提示風險、拒絕定時盯價或因聲明 AI 身分被客服掛斷。
- **Browser Use 能力**：OSWorld 評測中，OpenAI Astra 是最好的，Muse 的模型並沒有特別強。

6. AI晶片初創公司在AI算力市場份額及大參數的模型運算能力

- **聚焦 ASIC 推理晶片**：初創晶片公司多聚焦於 ASIC 推理晶片。若 Transformer 架構為最終解決方案，ASIC 晶片具備極高 ROI，將挑戰 NVIDIA 的 CUDA 護城河。
- **架構迭代風險**：若未來出現比 Transformer 更好的架構（如 Jeff Dean 所在 Discovery Lab 研究的 RSI 架構），專用型 ASIC 將面臨衝擊。
- **非定型領域仍偏好 GPU**：其他領域（World Model / 文生視頻 / Robotics / Multimodal Model）因模型架構尚未定型，仍偏好使用 GPU，主因 GPU 能快速將最新 Paper 實作出來。

7. CXL記憶體池方案

- **記憶體池**：技術已極為成熟（如 SGLang, vLLM, Fireworks AI），可將 KV Cache offload 至 DRAM 或 SSD。
- **CXL 記憶體池**：技術尚在發展初期，因需端到端的設備都支援 CXL 協定，目前主要受限於 GPU 與 TPU 對該協定的支援度不足。

8. 企業端 (To B) 落地挑戰與算力暴增瓶頸

- **To B 落地 Gap**：傳統企業無法準確估算 Token 費用，且對安全性疑慮重重；IT 部門缺乏搭設 Harness (LlamaIndex / CrewAI) 或微調經驗，極度依賴 **FDE (Forward Deployed Engineer)** 現場落地。
- **模型升級帶動算力指數消耗**：每代模型升級（如 Astra 6 vs Sol 5.6），單一任務 Token 消耗量暴增 2–3 倍。即使僅 10% 工程師升級，算力需求即呈數倍成長。加上資料中心 2 年建設週期落後於 Coding Agent 爆發速度，電力與設備瓶頸致使算力吃緊將長期持續。

二、Q&A

Q1：明年新增約 9mn 顆 TPU 是否合理？其中 Direct sales 給 Anthropic 的量有多少？

A: 明年有大概 700 萬顆上下，超過一半以上都是分配給 Anthropic 使用。

Q2 ：Gemini 推出新模型一個月後，普遍出現「降智」問題，是什麼原因造成的？面對龐大的用戶需求，是否會帶來沉重的算力成本負擔？

A：

- **模型降智的三大原因**：
    1. **思考等級動態調降**：如 Gemini 3.8 Flash 發布首週預設以 High Thinking 等級運行，一週後因全局算力吃緊，官方將免費/預設等級調降為 Medium（Anthropic 訂閱戶有時也會遇到預設等級被降為 Medium 的狀況）。由於 API 與模型收費係依據「輸出 Token」與「Cache 命中率」計算，而非依思考深度計費，廠商會動態降級以服務更多用戶。
    2. **模型蒸餾替換**：例如 Gemini 3.0 在今年 1 月進行了重大改版，替換為體積僅有原模型約 1/3 大小的蒸餾模型，導致用戶明顯感受到回答質量的變化。
    3. **分級模型配置**：如 Claude Fable 也是存在不同層級版本，切換不同 Thinking Level 背後所呼叫的模型尺寸與參數量可能相差一倍。
- **消費端算力與虧損壓力**：目前消費端 AI 服務普遍處於虧損狀態，各大廠商（特別是 OpenAI 與 Anthropic）正大力打擊各式薅羊毛行為（如淘寶販售共享帳戶、高頻呼叫等）。

Q3：怎麼看 Jeff Dean 離職的影響？

A：Jeff Dean 在 DeepMind 離職前主要負責硬體架構與 NVIDIA、Marvell 合作等底層設計，並不直接主導大模型（Model）本身的訓練。自 Gemini 2.5 以後，模型論文署名中已無其名字。因此，其離職對硬體與晶片架構設計會有一定衝擊，但對前沿模型研發的直接影響相對有限。

Q4：請問 Tier 1, Tier 2 model 分別是哪些公司？Gemini 4 Argon 算 Tier 1 了嗎？

A：Tier 1 模型定義為在 Agentic 綜合能力與基準評測中處於第一梯隊的模型。Argon 確定屬於 Tier 1，其在 Agentic 榜單中與前 5 大頂級模型並列第一，且在 Text 綜合評測中與 Muse Wonder Full 旗艦款平起平坐。

Q5：可否分享 AI for Science 的近況，模型商如何與生技公司、科技業合作？模型商是否會跟 Twist Bioscience 等公司購買生技數據？

A：

- 生命科學（Life Science）領域的瓶頸不在於 Token 數量或模型架構，而在於**缺乏足夠的物理/生物實驗驗證機制**（對比 3D 領域因有 Blender 等數位驗證器而進展迅速）。
- 目前模型商積極與生技企業合作，例如與 Twist Bioscience 進行深度數據與實驗驗證；Anthropic 亦在內部建立自身的 Wet Lab 進行實體驗證，因此該領域發展會相對慢一點。

Q6：在 DeepMind 的算力與未來新增算力低於 Anthropic & OpenAI 之下，是否會讓 Gemini 競爭力持續下滑？

A：GCP 目前將大量 TPU 算力優先給 Anthropic，Anthropic 所獲取的 TPU 總數甚至超過 DeepMind 自用。算力吃緊（加上 TPU v8i 交付延遲）直接導致 Gemini 新模型（如 Argon）延後了一個多月才發布。

DeepMind 內部留用於訓練的 TPU 僅約 60–70 萬張（含 v6/v7），算力限制確實對研發與發布節奏造成壓力。

Q7：如果 Gemini 競爭力持續弱於 Anthropic / OpenAI 是否會影響 Google Cloud 生意？

A：

- Argon 在 Agentic 與 Text 性能上已超越 OpenAI Astra 6 Max。
- GCP 的策略是推出按 Seat 計費的 Gemini Enterprise 套餐，當中直接預裝 Anthropic Claude 全系列模型。客戶購買該套餐即可同時呼叫 Gemini 與 Claude 模型（雖然底層 Harness 仍維持 Google 架構），此策略能有效留存 GCP 雲端客戶，降低單一模型競爭力波動帶來的營運風險。

Q8：怎麼看 Amazon 封殺 Muse 這件事？是否會影響未來 Agentic Commerce 的發展？

A：Muse 產品設計較為激進（如主動繞過驗證碼、代操作等），引發平台合規疑慮。相較之下，Google 採取較為保守的合約對接模式（已與星巴克、DoorDash、Uber、Spotify、Apple 等八九十家龍頭業者簽約，實現 Gemini 內直接下單）。Amazon 目前允許 Google AI 模式接入，若 Muse 欲進入 Amazon 生態，預計亦需透過商業協議達成合規授權。

Q9：先前 Google 與 SpaceX 簽訂 GPU 算力協議支援 Gemini Enterprise，可否分享一下外部客戶使用 GPU/TPU 的情境，以及 Google 會透過什麼方式讓外部客戶提高對 TPU 的使用量？

A：

GPU 算力這塊應該是這樣，因為 GCP 的訂單都是一種叫做「承諾消費訂單」。這類訂單客戶是會付錢的，因為有一些金融方面的擔保，而 Google 也有義務交付算力。如果無法交付，就會涉及很多法律責任。

所以 Google 現在確實在租用很多算力，來滿足他們的承諾。我個人覺得，很大一部分原因還是 TPU v8i 延遲到年底，因此年底之後可能會有大量算力釋出。

目前有很多大型企業客戶，像現在最大的客戶是 Intel，買了大概十幾萬個 Seats。這些 Seats 每個月幾十美元，Anthropic 除了 Frontier Model 以外，其他模型都可以使用，包括 Argon。

所以很多企業覺得這樣比較合適，只需要決定使用 Open 還是非 Open 的模型，就可以完成選擇，也就是一種綁定銷售的模式。

Q10：看好 Meta 透過 Muse 變現嗎？似乎消費者的付費意願遠不如 Coding 應用。

A：

Muse 變現其實不是非常好說。我個人覺得如果 Muse 要收訂閱費，可能並沒有這麼容易，很多用戶還是喜歡免費使用。因為現在北美這邊，能免費使用的個人助理只有 Muse，其他的要麼需要邀請，像 Perplexity / ChatGPT / Claude 那樣，要馬就是需要支付至少 100 美元。

當然，我覺得最關鍵的可能還不是費用，而是產品設計。Muse 做得非常激進，其他公司的產品經理可能擔心承擔責任，因此不敢做出類似的設計。

Q11：在廣告轉換率上還會有透過 AI 模型提升的空間嗎？

A：廣告轉換率我覺得現在距離還比較遠，因為整個任務的執行軌跡能不能用來做 Targeting，目前還不是很好說。我身邊很多使用 Muse 的人，平常喜歡在 Instagram 上開網店，例如販售自家烘焙的產品。像這類用戶，還是比較喜歡在 Muse 的生態裡做一些小生意，例如 Instagram Shop，並利用 Muse 進行一些 Automation。

Q12：怎麼看現在各家推出 Agentic AI 對算力需求增加的程度？會造成算力更加吃緊嗎？

A：

現在算力非常緊張。Argon 的算力緊張到從昨天下午開始，員工都不能再使用 Argon，只能使用測試模型。因為外部用戶需求增加非常多，而 Argon 是很大的模型，本身並沒有準備這麼多算力。

B 端用戶採取承諾消費模式，Google 有算力交付的承諾，必須確保這部分的算力供應。因此，實際能動用的算力目前並不是非常多。

Agentic AI 的算力需求要看使用方式，如果是 Coding，肯定會消耗非常多算力；但如果是一般使用，例如每隔幾個小時查詢一次票價，還是可以負擔的。如果是非正常使用，就會消耗大量算力。

舉個例子，現在正專門打擊共享帳戶。我聽一些大陸的人說，有人把每月 200 美元的帳戶拿到淘寶上，按單條問題回答販售，每個月基本上能賣出超過 1 萬人民幣。因此，目前主要在打擊這類帳戶濫用行為，算力供應還是非常緊張。

Q13：先前有傳聞 Anthropic 向 Google 接洽想收下目前 DeepMind 所有的 TPU 算力，想請問 Google 內部如何平衡自用和銷售的佔比？

A：

現在確實有傳聞說 Anthropic 想收下 DeepMind 所有的算力。實際上，Anthropic 確實需要購買大量算力，因為 Claude Fable 都是在 TPU 上做的。另外，它的 Opus Model 是一個 Student Model，基於 Fable 做半蒸餾而來，所以 TPU 算力對 Anthropic 相當關鍵。

不過，我一開始有提過，明年大概有超過 50% 的 TPU 都會分配給 Anthropic，這可能已經是 Google 能夠支援 Anthropic 的最大限度。目前算力供應還是很緊張，也沒有特別好的解決辦法。現在 DeepMind 用於訓練的 TPU 大概有六、七十萬片，包含 v6 和 v7，大致是這樣的狀況。