

TOKEN IS BECOMING

Electricity

The Next AI Investment Paradigm

當 Token 成本被中國開源模型壓低，模型層開始商品化；價值轉移到大量消耗 Token 的應用與工作流平台。

Cost ↓

Demand ↑

Value Chain Reset

歷史正在重演：電力如何從商品化走向應用大爆發

電力用了七十年走過「建設 → 擴張 → 商品化 → 應用大爆發」；同樣的順序，正在 Token 身上重演。

01 基礎建設期

電力

1880s-1900s
AC/DC 電流之戰，發電廠與電網從零建設
贏家：GE、Westinghouse

Token

2022-2024
GPU／資料中心大規模擴產，算力軍備競賽
贏家：NVDA、TSMC、先進封裝、電力鏈

02 標準化與擴張期

電力

1900s-1930s
電網互聯、鄉村電氣化；每度電價
\$4.53→\$0.62 (-86%)
贏家：區域電力公司、GE 電機設備

Token

2024-2026
DeepSeek／Qwen／Kimi 成為價格
錨，Token 成本崩落 17-55x（開源方多半
未獲利）
贏家：OpenRouter、AWS／Azure／GCP

03 商品化期

電力

1930s-1960s
電力變成計量公用事業；電價續降至
\$0.09/kWh
贏家：大型工業用電戶、公用事業集團

Token

2026 現在
Token 變成 Metered Utility；Commodity vs
Frontier 正式分層
贏家：前沿模型保有溢價（OpenAI／
Anthropic／Google）

04 應用大爆發期 ★

電力

1920s-1950s
電氣化生產線（Ford Model T：
12hr→93min）、家電消費品普及
贏家：Ford、GE／Westinghouse 家電、零售
通路

Token

現在進行式
工作流與 Agent 平台，把便宜 Token 轉成
收入與毛利
贏家：PLTR、NOW、CRM、META、AMZN

歷史教訓：電力時代最大財富不是電廠賺走的，而是把便宜電力轉成新商業模式的公司賺走的——這正是「Overweight 應用層」的歷史根據。

Executive Summary：這不是降價新聞，而是價值鏈重組

整份簡報只講一件事：Token 成為 Utility 之後，投資重心要從「模型」移向「應用與工作流」。

1

Token 成本崩落

DeepSeek / Qwen / Kimi 等中國開源模型成為價格錨，讓中低階任務成本大幅下降。

2

美企開始 Routing

OpenRouter 中國模型 Token 佔比從 4.5% 升至 46%；企業把低敏任務導向便宜模型。

3


利潤往兩端移動

上端硬體吃總量成長；下端應用吃毛利擴張；中間純模型 API 承壓。

結論：不要投資 Token 本身；投資 Token 爆炸成長後，能把它轉成收入與毛利的公司。

Token 成本崩落：中國開源模型成為 Price Setter

同樣月跑 10 億 Token 的應用，DeepSeek V4-Pro 月帳單約 \$522，對比 Claude / GPT 約 \$9,000-\$10,000。



17–19x

價差：DeepSeek vs frontier models

36–55x

最便宜輸入 Token 層級價差

這一頁要保留：它是整份投資敘事的「第一性證據」。

為什麼成本掉這麼快？五層疊加

成本下降不是單一促銷，而是模型結構、系統工程、緩存、補貼與追隨者紅利同時作用。



未來 Token 成本持續下降的方向：五層技術棧與受益者

光通訊只是其中一層；成本下降的下一階段，來自硬體、記憶體、互連、演算法、電力五層同步推進，優先序決定資金配置順序。

1	互連／傳輸層 機櫃內 Scale-Up：銅轉光（CPO／矽光子）	XPU 之間以矽光子整合取代銅纜，傳輸距離達電纜 100 倍，直接提升算力利用率	嘉基、天孚通信、上詮、波若威、Lumentum、Coherent、Broadcom、Marvell	最確定
2	記憶體層 HBM 頻寬升級 + 運算／記憶體解耦架構	推理成本瓶頸常是記憶體頻寬而非算力；先進封裝（TSV／CoWoS）與解耦架構可同時降成本與功耗	先進封裝／HBM 供應鏈（CoWoS／CoPoS 生態）— 目前覆蓋最少，建議新增深挖	待深挖
3	電力層 每 Token 的物理成本底線：電力效率	變壓器前置時間拉長至 3-5 年、GOES 矽鋼供給瓶頸，護城河比既有台廠部位更上游、更難被取代	GE Vernova、Eaton、Vertiv（美）／日立能源、三菱電機、富士電機（日）	上修覆蓋
4	晶片架構層 客製 ASIC（TPU／Trainium／Maia）+ MoE 極致化	邊際效益遞減，容易做的部分多已完成，但仍是 CSP 壓低 COGS 的主要武器	TSMC（製程護城河兩邊通吃）、Broadcom／Marvell（協同設計）	既有覆蓋
5	演算法／系統層 Speculative Decoding、量化、KV Cache 壓縮	不需換硬體即可提升吞吐量；進展速度快於硬體迭代，但難有單一上市公司獨享	無直接標的 — 持續壓縮純模型 API 定價權，強化 Underweight 判斷	無標的

結論：光通訊（互連層）是目前最確定、資金最快落地的方向；記憶體解耦架構是覆蓋最少、報酬潛力最被低估的一塊，建議列為下一步研究優先項目。

Open Source 改變遊戲規則：能力擴散比價格更重要

一旦模型能力被開源化，企業不再只買單一模型；它們開始買「模型組合」與「動態路由」。



以前

企業選一個最強模型




現在

企業把每個任務丟給最便宜且足夠好的模型

核心轉變： Selection → Routing

美國公司已開始把中國模型放進 workflow

OpenRouter 顯示：美企路由到中國模型的 Token 佔比，從 2025 H1 約 4.5%，升到 2026 峰值約 46%。




企業實例

- **Coinbase**：1,200 個 Agent 改跑中國模型，支出砍半
- **Airbnb**：客服 Agent 採用 Qwen，解決時間縮短
- **Uber**：非急迫任務導向便宜模型
- **Cursor**：被市場認為導入 Kimi 能力

美國企業沒有排斥開源／中國模型；它們把模型當成成本、延遲、準確率的最佳化問題。

AI 正在變成 Routing Problem

未來不是單一模型吃掉全部任務，而是每個任務由 Router 判斷：安全性、成本、延遲、能力，再選擇模型。



投資含義：掌握「工作流入口」與「Router」的公司，比單一模型公司更接近價值捕捉點。

Amazon（AWS Bedrock Prompt Routing）已產品化並有收入，但僅限同模型家族內路由；跨供應商路由目前仍由獨立新創主導，尚無單一龍頭卡位。

Token 市場正式分層：Commodity vs Frontier

中低階任務被商品化，前沿／監管工作負擔仍可保有溢價；純模型 API 是價值鏈中最危險的位置。

Commodity Intelligence

- 分類、草稿、Code Scaffolding、簡單 Agent
- 中國開源模型主導價格戰
- 毛利可能被壓到接近 Utility
- 不需要最強模型來寫 email


Frontier / Regulated

- 複雜推理、多模態、受監管任務
- OpenAI / Anthropic / Google 仍有溢價
- 高難度 10-20% 任務維持利潤池
- 平台、工具、合規層創造黏性

結論：Token 正在大宗商品化，但智能本身不是；價值集中在「前沿能力」與「工作流交付」。

利潤流向價值鏈兩端：上端硬體，下端應用

Token 總量爆炸支撐硬體需求；但成本下降最直接改善的是應用公司的 COGS 與毛利。



投資框架：上端硬體吃「Token 總量」；下端應用吃「單位成本下降」；中間純模型 API 最容易被擠壓。

誰受益？把公司放回價值鏈，而不是只看題材

AI 投資要避免把所有 AI 公司混在一起；同樣是 AI，受益機制完全不同。

● 上端：算力硬體

NVDA / AVGO / TSMC / 先進封裝 / 電力鏈

中性偏多：Token 總量爆炸仍支撐硬體，但估值與中國全棧化是風險。

● 下端：應用與工作流

PLTR / NOW / CRM / META / AMZN

最大贏家：COGS 被便宜模型壓低，收入賣的是工作流與結果。

● 中間：純模型 API

OpenAI / Anthropic 中低階 API

承壓：商品化與價格戰侵蝕定價權，必須往平台與企業合約轉型。

● 雲平台：CSP 分化

AWS / Azure / GCP

微妙：開源權重仍跑在美國雲上，Hosting 反成收入，但模型 API 定價權流失。

投資策略：資金配置要偏向「應用 + 工作流」

不是賣掉所有硬體，而是把新增資金放在成本下降的最大受益者。

Overweight	Application / Workflow NOW, PLTR, META, AMZN Token 成本下降直接擴張毛利與 TAM
Hold / Neutral	Infrastructure NVDA, AVGO, TSMC 仍受惠量成長，但估值與供應鏈風險較高
Underweight	Pure Model API 中低階模型 API 價格戰、開源替代、企業 Routing 造成壓力

一句話：Own the application layer — and keep the infra core, but do not overpay for pure model pricing power.

風險與結論：Token 是大宗商品，智能不是

最大風險是政策與地緣政治，但只要成本曲線繼續下行，應用層的受益邏輯仍成立。

Key Risks

- 美方限制中國模型進入企業工作流
- 中方限制海外 API / 權重存取
- OpenAI / Anthropic 快速降價反擊
- 企業採用速度低於預期
- 中國全棧化削弱 NVIDIA 供應鏈外溢效益

Three Takeaways

- 1 Token 是大宗商品，智能不是
- 2 利潤流向價值鏈兩端
- 3 資金應偏向應用與工作流

Token is Becoming Electricity