



一、代理式 AI (Agentic AI) 時代的降臨與全新運算模式

- **軟體開發典範轉移**：AI 已從生成式 AI 演進至具備實用生產力的代理式 AI (Agentic AI)。全球約有 3000 至 4000 萬名軟體開發者，GitHub 的程式碼提交量 (Commits) 在 2023 年為 3 億次，2024 年達 4 億次，2025 年為 5 億次，而在 2026 年前幾個月內更飆升了近三倍。
- **「算力即營收」的經濟規模**：這項轉變讓原先 3 兆美元的薪資能創造出高達 9 兆美元的生產價值，大幅推升了企業對 AI 運算 (Token 產出) 的獲利需求，直接帶動運算需求的爆發。
- **全新的運算架構**：過往的「應用程式 + 作業系統」已轉變為「模型 + 代理框架 (Harness) + 工具與技能 + 執行環境 (Runtime)」的解耦分散式系統。
- **CUDA-X 函式庫化身代理工具**：代理 AI 現在能直接呼叫 NVIDIA 豐富的 CUDA-X 函式庫作為其解決問題的工​​具，包含 cuDF (資料處理)、cuOpt (決策最佳化)、QDSS (稀疏求解器)、AI-Q (智慧路由與知識工作流)、NeMo、PhysicsNeMo (高保真 AI 物理模型)、CUDA-Q (量子運算) 以及 Parabricks (基因體學) 等。





二、Vera Rubin 進入全面量產與 NVIDIA DSX AI 工廠平台

- **Vera Rubin 全面量產**：專為代理式工作負載設計的多機櫃 (POD) 系統 Vera Rubin 已全面量產。其供應鏈規模是前一代 Grace Blackwell 的兩倍，在台積電等 150 家台灣供應鏈夥伴協助下，單一機櫃的組裝時間從過去的 2 小時大幅縮減至 5 分鐘。相較於 Grace Blackwell 平台，Vera Rubin 帶來了 10 倍的系統級代理運算吞吐量。
- **平台硬體配置**：
 - **Vera Rubin NVL72**：處理思考與情境理解，擁有高達 6 兆個電晶體。
 - **Groq 3 LPX (LPU30)**：專為極低延遲推論設計，提供 40 PB/s 的 SRAM 頻寬。
 - **Vera BlueField-4 STX 儲存系統**：內建硬體級安全防護。搭載 NVIDIA DOCA 軟體 (Vault、Argus、Flow)，可提供比現有方案快 1000 倍的執行時期威脅偵測，並能以高達 800Gb/s 的速度執行網路與檔案存取策略。


- **Spectrum-X Ethernet Photonics (Spectrum-6 SPX)**：全球首款配備 200Gb/s SerDes 及共封裝光學 (CPO) 的乙太網路交換器。能源效率提升 5 倍、AI 正常運作時間延長 5 倍、部署時間縮短 1.3 倍，為百萬級 GPU AI 工廠奠定網路基礎。





Vera rubin, Groq LPX, Vera CPU, STX, Networking CPO




Vera rubin, Vera CPU 托盤, DPU 儲存托盤



LPX, Vera rubin switch, 乙太網路 Switch 托盤




- **NVIDIA DSX AI 工廠平台**：為應對動輒投資數百億美元的 1 GW 級距別 AI 工廠，NVIDIA 提供完整的基礎設施軟硬體方案。
 - **DSX MaxLPS**：結合 45°C 液冷與機櫃內最佳化技術，能在相同的電力預算下增加高達 40% 的 GPU 部署量，實現最低的 Token 成本。
 - **DSX Sim**：高保真度的數位孿生模擬層，可在硬體進場前驗證設計。
 - **DSX Flex**：使 AI 工廠能根據電網訊號動態調節負載。



三、 專為 AI 代理設計的 CPU — NVIDIA Vera

- **Vera CPU**：有別於過往為人類設計的 CPU，Vera 是專為講求超低延遲與極快反應的代理式 AI 設計。目前已有包括紐約證交所、Anthropic、OpenAI 等機構採用。
- **規格與效能突破**：
 - 具備 **88 顆 Olympus 核心**，單執行緒效能(IPC)極高，每時脈週期可抓取與解碼 10 個指令。
 - 領先業界搭載 **LPDDR5X 記憶體**，提供高達 **1.2 TB/s 頻寬**，峰值記憶體延遲比 x86 降低 **40%**。
 - 晶片內核心通訊採無邊界限制的互連架構，提供 **3.6 TB/s 頻寬**；透過第二代 NVLink-C2C 技術，CPU 與 GPU 間具備 **1.8 TB/s 一致性頻寬**。
 - 整體代理沙盒執行效能比 x86 處理器快 **1.8 倍**。在 SQL 資料庫處理快了 **3 倍**；在紐約證券交易所的即時串流處理速度更是提升了 **6 倍**。

NVIDIA Vera – CPU for the Age of AI



NVIDIA Vera CPU for Agents

NVIDIA-Custom Olympus Core

88-Core / 176-Threads
Spatial Multithreading

10-Wide Instruction Fetch/Decode

2MB L2 per Core / 164MB L3

250W - 450W TDP



1.2 TB/s LPDDR5X ECC


40% Lower Loaded Latency
(vs x86)

3.4 TB/s Core-to-Core BW

1.4 TB/s PCIe Gen6

1.8 TB/s NVLink C2C





88 NVIDIA Custom Olympus Core
With Spatial Multithreading


PCIe Gen 6 CXL 3.1

164 MB L3 Cache

3.4 TB/s Core-to-Core
Bisection Bandwidth

Up to 1.5 TB LPDDR5X Memory

NVLink-C2C 1.8 TB/s Coherent
CPU-CPU and CPU-GPU Interface




*"NVIDIA Vera is the most formidable
competition to Intel and AMD x86_64
processors ever realized."*

Michael Larabel
Author, Phoronix CPU Benchmark Suite

Vera CPU 3X Faster SQL Data Processing

*"With Starburst on NVIDIA Vera CPUs with Dell, agents can instantly query governed enterprise data at scale,
unlocking the ground truth to power decisions at the speed the agentic era requires."*

— Justin Borgman, CEO and Founder of Starburst



NVIDIA Vera Opens Large Market CPU for Agents




四、企業 AI 代理工具包與開源模型

- 企業專屬工具：NVIDIA 推出 Agent Toolkit，包含開放的 **NemoClaw** 藍圖，以及確保企業安全與隱私防護的 **OpenShell** 執行環境。
- Cadence 晶片設計應用**：透過 NVIDIA OpenShell 與代理技術，Cadence 推出的 **ChipStack** 超級代理，能自主執行 RTL 驗證與回歸測試，將原本耗時數週的工程週期縮短至「幾小時內」，速度提升高達 **40 倍**。




- Nemotron 3 Ultra 模型發布**：專為長時運行的代理打造。具備 **5,550 億參數**，採用結合 **SSM** 與混合專家系統 (MoE) 的架構。推論速度提升高達 **5 倍**，且成本比同級開放邊緣模型低 **30%**。



五、重塑 Windows PC 體驗與 RTX Spark 平台

- NVIDIA RTX Spark 超級晶片**：NVIDIA 與微軟合作，在 40 年後首度徹底重新定義 PC，將其從單純的工具轉變為個人的 AI 隊友。
- 硬體規格**：
 - 採 TSMC 3 奈米製程，封裝 **700 億個電晶體**。
 - 搭載具備 **6,144 個 CUDA 核心**的 Blackwell RTX GPU (支援 FP4 第五代 Tensor 核心)，以及與聯發科 (MediaTek) 合作設計的 **20 核心 Grace CPU**。



- 提供 **128GB 統一記憶體**，具備 **1 Petaflop** 的驚人 AI 運算能力。
- **實機效能表現**：能流暢渲染 **90GB 的超大型 3D 場景**、剪輯 **12K 4:2:2 影片**、在本地端運行具備 **100 萬 Token** 上下文的 **1,200 億參數大型語言模型**，並能以 **1440p 解析度**與**超過 100 FPS** 的高幀率執行 **3A 遊戲大作**。Adobe Photoshop 與 Premiere 的 AI 與繪圖運算將獲得高達 **2 倍**的速度提升。
- **產品設計與上市時間**：筆電產品螢幕尺寸介於 **14 到 16 吋**，最薄處僅 **14 毫米**，重量約 **3 磅**，搭配 **OLED 顯示器**與**全天候電池續航**。預計於**今年秋季**由 **ASUS、Dell、HP** 等大廠推出。
- **DGX Station for Windows 桌邊超級電腦**：專為企業開發者設計，搭載 **GB300 Grace Blackwell Ultra Desktop** 超級晶片(包含 **72 核心 Grace CPU**)，可配置高達 **748GB 記憶體**。其具備 **20 Petaflops FP4** 效能，並支援 **800Gb/s** 的 **ConnectX-8 SuperNIC**，能單機運行 **1 兆參數**的頂級 AI 模型，預計今年第四季問世。



Announcing NVIDIA and Microsoft Reinvent PC

Powered by RTX Spark

- Blackwell RTX GPU**
1 Petaflop FP4 AI Performance
- 20 Core Grace CPU**
Custom Built with MediaTek
- 128 GB Unified Memory**
600 GB/s NVLink C2C
- Full NVIDIA Stack**
CUDA | TensorRT | NVFP4
RTX Ray Tracing | DLSS | Reflex | G-SYNC



六、實體 AI (Physical AI) 模型與參考平台

- **NVIDIA Cosmos 3 模型**：全球首款針對物理 AI 打造的完全開源全能模型。採用「混合 Transformer」架構，結合視覺推論、世界生成與動作預測。依照體積效能區分為 Cosmos 3 Super、Nano 以及即將推出的 Edge 版本。
- **自駕車與 Alpamayo 2**：推出為機器計程車設計的開放推理模型 Alpamayo 2。透過 DRIVE Hyperion 平台，鴻海計畫於 2028 年在高雄推行 Level 4 機器計程車服務；Uber 將在慕尼黑部署；VinFast 鎖定東南亞市場；HUMAIN 則負責佈局沙烏地阿拉伯。
- **Isaac GR00T 參考人形機器人**：專為學術與前沿研究設計的軟硬體一體機。
 - **物理規格**：與 Unitree 合作，站立高度將近 6 呎 (約 180 公分)，重量 150 磅。全身具備 31 個自由度，搭配 Sharpa 觸覺五指手 (雙手共 22 個自由度)，總計 75 個自由度。
 - **強大動能與運算**：手臂扭力高達 120 Nm，腿部高達 360 Nm；手臂額定負載為 7 公斤，峰值可達 15 公斤。內建 Jetson AGX Thor T5000 運算平台 (含 Blackwell GPU，算力達 2070 TFLOPS，14 核 Arm CPU 及 128GB 記憶體)。
 - **配備與續航**：配備 140 度水平及 102 度垂直廣角頭戴立體攝影機；搭載 15Ah (0.972kWh) 電池，可運作約 3 小時。預計將於 2026 年末由 Unitree 提供。

